04 - Types de données et transformations

PRO1036 - Analyse de données scientifiques en R

Tim Bollé

September 30, 2024

UQTR
Université du Québec à Trois-Rivières

Pourquoi s’intéresser aux types de données ?

Exemple: Cat lovers

Un sondage a demandé à des gens leur nom et le nombre de chat qu'ils possèdent. Les instructions indiquaient d'entrer le nombre de chats en chiffres.

```
cat_lovers <- read_csv("data/cat-lovers.csv")
```

```
# A tibble: 60 × 3
   name           number_of_cats handedness
   <chr>          <chr>          <chr>
 1 Bernice Warren 0              left
 2 Woodrow Stone  0              left
 3 Willie Bass    1              left
 4 Tyrone Estrada 3              left
 5 Alex Daniels   3              left
 6 Jane Bates     2              left
 7 Latoya Simpson 1              left
 8 Darin Woods    1              left
 9 Agnes Cobb     0              left
10 Tabitha Grant  0              left
# ℹ 50 more rows
```

Statistique simple…

```
1 cat_lovers %>%
2   summarise(mean_cats = mean(number_of_cats))
```

```
# A tibble: 1 × 1
  mean_cats
      <dbl>
1        NA
```

Ca ne marche pas…

Pourquoi ?

```
1  ?mean
```

mean {base} R Documentation

Arithmetic Mean

Description

Generic function for the (trimmed) arithmetic mean.

Usage

```
mean(x, ...)

## Default S3 method:
mean(x, trim = 0, na.rm = FALSE, ...)
```

Arguments

`x`	An `R` object. Currently there are methods for numeric/logical vectors and date, date-time and time interval objects. Complex vectors are allowed for `trim = 0`, only.
`trim`	the fraction (0 to 0.5) of observations to be trimmed from each end of `x` before the mean is computed. Values of trim outside that range are taken as the nearest endpoint.
`na.rm`	a logical value indicating whether `NA` values should be stripped before the computation proceeds.
`...`	further arguments passed to or from other methods.

Et maintenant ?

```
  1  cat_lovers %>%
  2    summarise(mean_cats = mean(number_of_cats, na.rm = TRUE))
```

```
# A tibble: 1 × 1
  mean_cats
      <dbl>
1        NA
```

Toujours pas…

Regardons les données

```
1 glimpse(cat_lovers)
```

```
Rows: 60
Columns: 3
$ name           <chr> "Bernice Warren", "Woodrow Stone", "Willie Bass", "Tyro…
$ number_of_cats <chr> "0", "0", "1", "3", "3", "2", "1", "1", "0", "0", "0", …
$ handedness     <chr> "left", "left", "left", "left", "left", "left", "left",…
```

Regardons cela de plus près

Show 10 entries Search:

	name	number_of_cats	handedness
1	Bernice Warren	0	left
2	Woodrow Stone	0	left
3	Willie Bass	1	left
4	Tyrone Estrada	3	left
5	Alex Daniels	3	left
6	Jane Bates	2	left
7	Latoya Simpson	1	left
8	Darin Woods	1	left
9	Agnes Cobb	0	left
10	Tabitha Grant	0	left

Showing 1 to 10 of 60 entries Previous 1 2 3 4 5 6 Next

UQTR Université du Québec à Trois-Rivières

Respecter les types de données

```r
cat_lovers %>%
  mutate(
    number_of_cats = case_when(
      name == "Ginger Clark" ~ "2",
      name == "Doug Bass"    ~ "3",
      TRUE                   ~ number_of_cats
      ),
    number_of_cats = as.numeric(number_of_cats)
    ) %>%
  summarise(mean_cats = mean(number_of_cats))
```

```
# A tibble: 1 × 1
  mean_cats
      <dbl>
1     0.833
```

Enregistrer

```
cat_lovers <- cat_lovers %>%
  mutate(
    number_of_cats = case_when(
      name == "Ginger Clark" ~ "2",
      name == "Doug Bass"    ~ "3",
      TRUE                   ~ number_of_cats
      ),
    number_of_cats = as.numeric(number_of_cats)
    )
```

Morale

- Si vos données ne se comportent pas comme vous l'attendez, il se peut qu'il s'agisse d'un probplème de type de données.
- Explorez et investiguez vos données, appliquez les modifications, *sauvegardez vos données*, vivez heureux

Types de données

Types de données dans R

- logical
- double
- integer
- character
- Il y a en d’autres mais nous les utiliserons peu

Logical et character

logical - Valeurs booléennes TRUE et FALSE

```
1 typeof(TRUE)
```

```
[1] "logical"
```

character - Texte

```
1 typeof("Hello")
```

```
[1] "character"
```

Double et integer

double - Nombres à virgule flottante (type par défaut pour les nombres)

```
1 typeof(1.5)
```

```
[1] "double"
```

```
1 typeof(7)
```

```
[1] "double"
```

integer - Nombres entiers (indiqué par un L)

```
1 typeof(1L)
```

```
[1] "integer"
```

```
1 typeof(1:3)
```

```
[1] "integer"
```

Concatenation

Des vecteurs peuvent être construits à l'aide de la fonction `c()`

```
1 c(1, 2, 3)
```

```
[1] 1 2 3
```

```
1 c("Hello", "World!")
```

```
[1] "Hello"  "World!"
```

```
1 c(c("hi", "hello"), c("bye", "jello"))
```

```
[1] "hi"    "hello" "bye"   "jello"
```

Conversion

... intentionnelle

```
1 x <- 1:3
2 x
```

```
[1] 1 2 3
```

```
1 typeof(x)
```

```
[1] "integer"
```

```
1 y <- as.character(x)
2 y
```

```
[1] "1" "2" "3"
```

```
1 typeof(y)
```

```
[1] "character"
```

```
1 x <- c(TRUE, FALSE)
2 x
```

```
[1]  TRUE FALSE
```

```
1 typeof(x)
```

```
[1] "logical"
```

```
1 y <- as.numeric(x)
2 y
```

```
[1] 1 0
```

```
1 typeof(y)
```

```
[1] "double"
```


UQTR Université du Québec à Trois-Rivières

Conversion

… accidentelle

R va faire les conversions sans se poser de questions, surtout quand on mets différentes choses dans un même vecteur.

```
1 c(1, "Hello")
```

```
[1] "1"     "Hello"
```

```
1 c(FALSE, 3L)
```

```
[1] 0 3
```

```
1 c(1.2, 3L)
```

```
[1] 1.2 3.0
```

```
1 c(2L, "two")
```

```
[1] "2"   "two"
```

Conversion

- Explicite - Utilisez les fonctions `as.*()`
  - `as.logical()`
  - `as.numeric()`
  - `as.integer()`
  - `as.character()`
  - `as.double()`
- Implicite - R va faire les conversions pour vous, soyez vigilant

Cas spéciaux

Cas spéciaux

- `NA` - Valeur manquante
- `Inf` - Infini
- `NaN` - Not a Number

```
1 # division par zéro -> Inf
2 7/0
```

```
[1] Inf
```

```
1 -1/0
```

```
[1] -Inf
```

```
1 Inf - Inf
```

```
[1] NaN
```

NA

```r
x <- c(1, 2, 3, 4, NA)
```

```r
mean(x)
```

```
[1] NA
```

```r
mean(x, na.rm = TRUE)
```

```
[1] 2.5
```

```r
summary(x)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
   1.00    1.75    2.50    2.50    3.25    4.00       1
```

NA

Les NA sont utilisés par R pour représenter des valeurs manquantes. Ils sont de type logique.

```
typeof(NA)
```

```
[1] "logical"
```

```
# TRUE or NA
TRUE | NA
```

```
[1] TRUE
```

```
# FALSE or NA
FALSE | NA
```

```
[1] NA
```

Classes de données

Classes de données

Nous avons parlé des *types* des données et nous allons maintenant parler des *classes* des données:

- Vecteurs sont comme des briques LEGO
- On les colle ensemble pour construire des structures plus compliquées, notamment des *représentations de données*

Par exemples:

- factor
- date
- data frame

factor

Les facteurs sont utilisés pour gérer les variables catégorielles, c'est-à-dire les variables qui ont un ensemble fixe et connu de valeurs possibles.

```r
x <- factor(c("BS", "MS", "PhD", "MS"))
x
```

```
[1] BS  MS  PhD MS
Levels: BS MS PhD
```

```r
typeof(x)
```

```
[1] "integer"
```

```r
class(x)
```

```
[1] "factor"
```


UQTR Université du Québec à Trois-Rivières

factor

Pour chaque facteur on a:

- `levels` - Les valeurs possibles
- `labels` - Les étiquettes associées aux valeurs

```
1 glimpse(x)
```

```
Factor w/ 3 levels "BS","MS","PhD": 1 2 3 2
```

```
1 as.integer(x)
```

```
[1] 1 2 3 2
```

Dates

```
1 y <- as.Date("2024-01-01")
2 y
```

```
[1] "2024-01-01"
```

```
1 typeof(y)
```

```
[1] "double"
```

```
1 class(y)
```

```
[1] "Date"
```

Dates

Les dates sont en réalité un entier (le nombre de jours depuis l'origine, 1 Jan 1970) et un entier (l'origine) collés ensemble

```
1 as.integer(y)
```

```
[1] 19723
```

```
1 as.integer(y) / 365
```

```
[1] 54.03562
```

Data frames

Les data frames sont des structures de données qui sont comme des vecteurs de différentes classes.

```
1 df <- data.frame(x = 1:2, y = 3:4)
2 df
```

```
  x y
1 1 3
2 2 4
```

```
1 typeof(df)
```

```
[1] "list"
```

```
1 class(df)
```

```
[1] "data.frame"
```

Listes

Les listes sont des conteneurs génériques pour des vecteurs de n'importe quel type.

```r
l <- list(
  x = 1:4,
  y = c("hi", "hello", "jello"),
  z = c(TRUE, FALSE)
)
l
```

```
$x
[1] 1 2 3 4

$y
[1] "hi"    "hello" "jello"

$z
[1]  TRUE FALSE
```

Listes et data frames

- Un data frame est une liste spéciale contenant des vecteurs de longueur égale
- Lorsque nous utilisons la fonction `pull()`, nous extrayons un vecteur du data frame

```
1 df
```

```
  x y
1 1 3
2 2 4
```

```
1 df %>%
2   pull(y)
```

```
[1] 3 4
```

Travailler avec des facteurs

Exemple: Cat lovers

Nous commençons avec un data frame avec des caractères

```
1 glimpse(cat_lovers)
```

```
Rows: 60
Columns: 3
$ name           <chr> "Bernice Warren", "Woodrow Stone", "Willie Bass", "Tyro…
$ number_of_cats <chr> "0", "0", "1", "3", "3", "2", "1", "1", "0", "0", "0", …
$ handedness     <chr> "left", "left", "left", "left", "left", "left", "left",…
```


UQTR Université du Québec à Trois-Rivières

Plotting

Au moment de faire un graphique, R va faire une conversion de type

Si on lui demande de plotter des catégories, il va créer des facteurs

```
1  ggplot(cat_lovers, mapping = aes(x = handedness)) +
2    geom_bar()
```

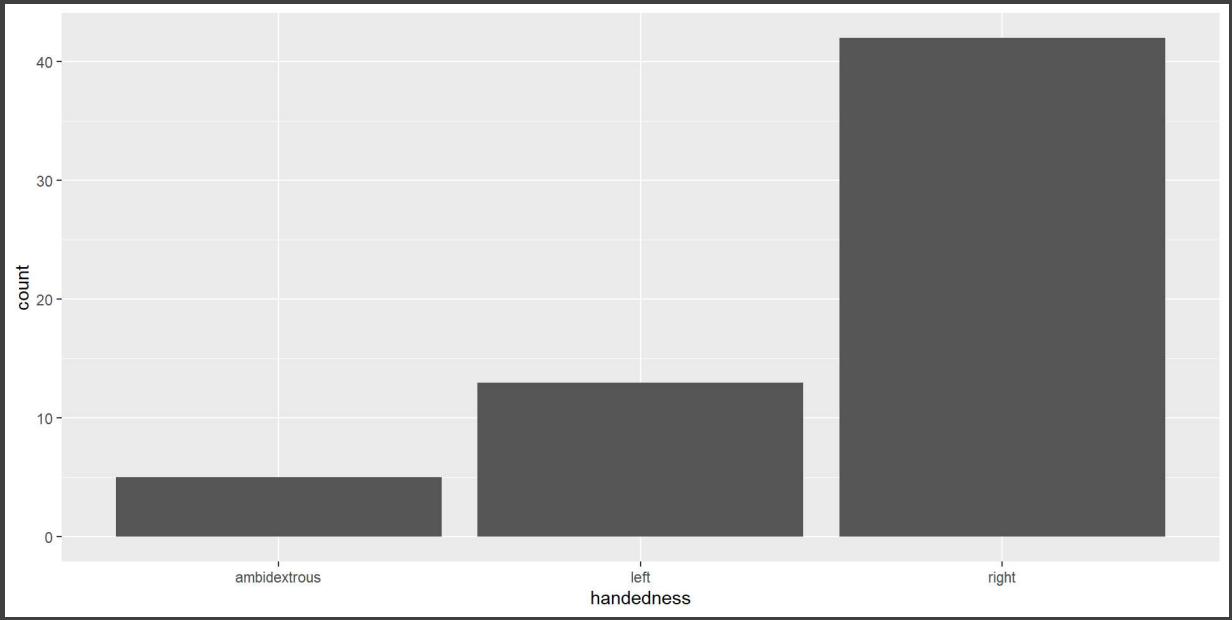

Les facteurs sont ordonnées par ordre alphabétique par défaut

UQTR Université du Québec à Trois-Rivières

On peut manipuler les facteurs avec forcats

```
1 cat_lovers %>%
2   mutate(handedness = fct_infreq(handedness)) %>%
3   ggplot(mapping = aes(x = handedness)) +
4   geom_bar()
```

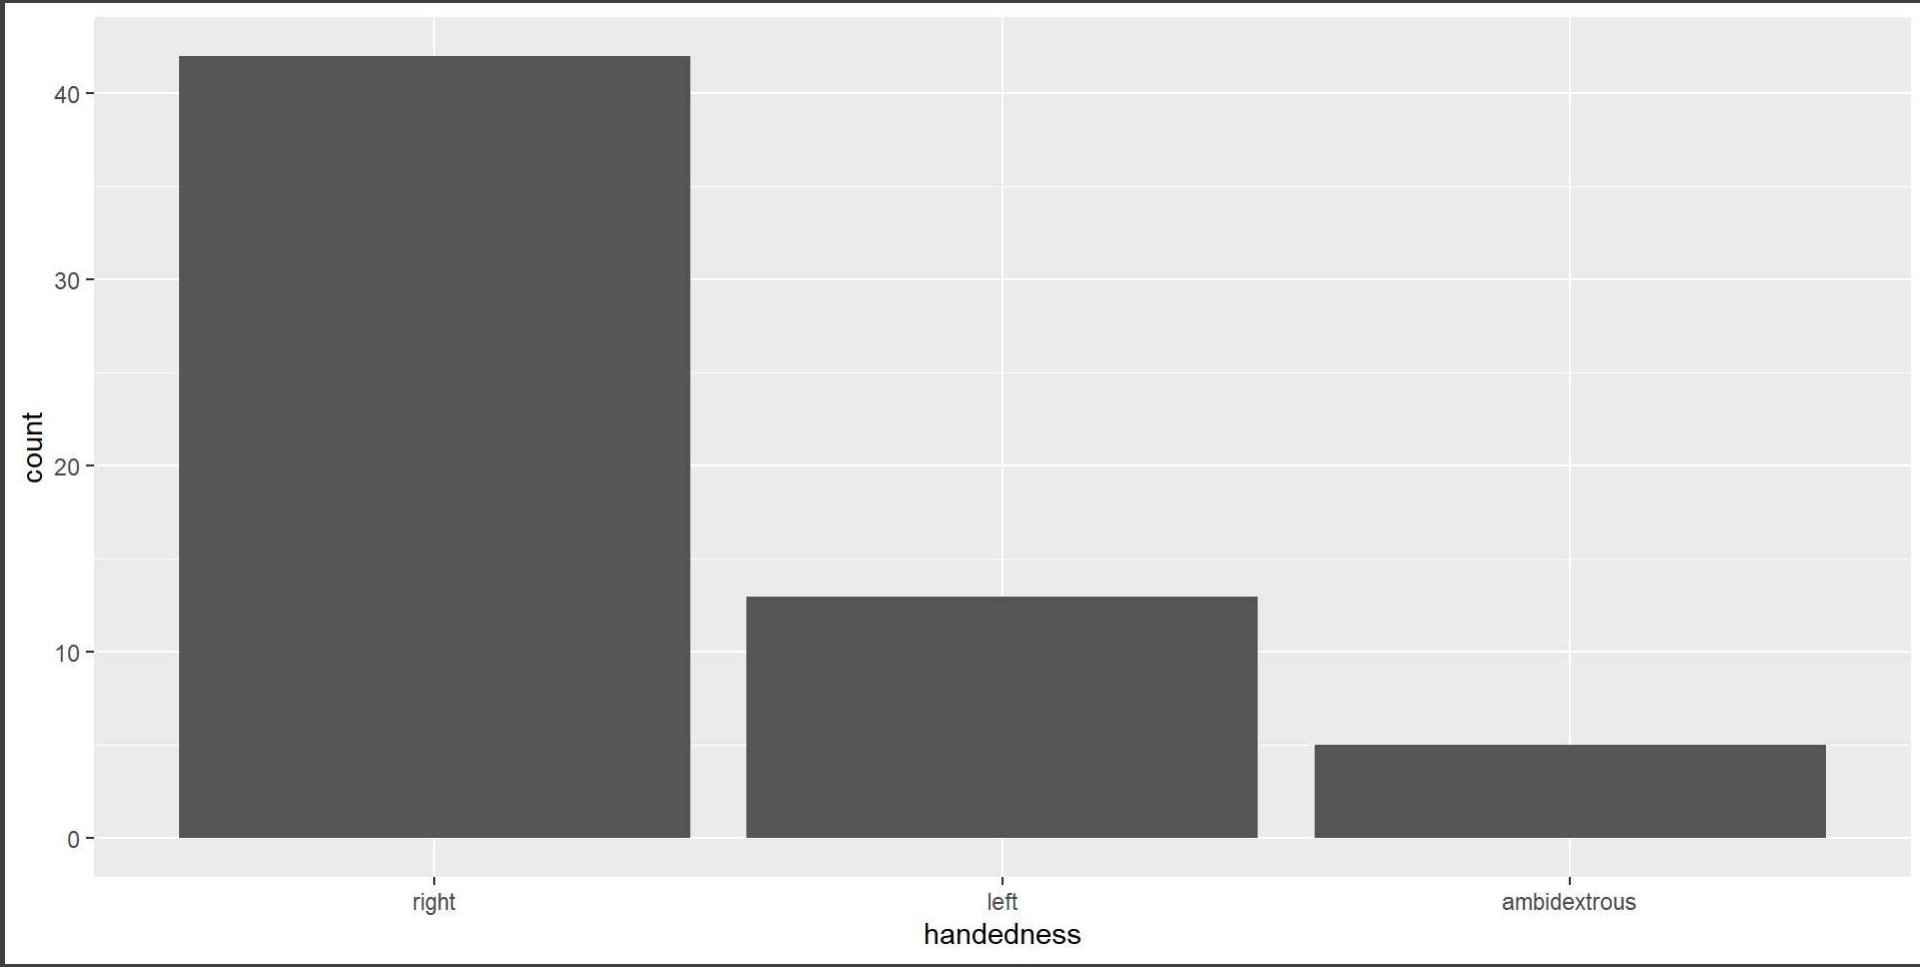

UQTR Université du Québec à Trois-Rivières

La grammaire de la manipulation de données

Basé sur des fonctions qui correspondent à des verbes permettant de manipuler des dataframes.

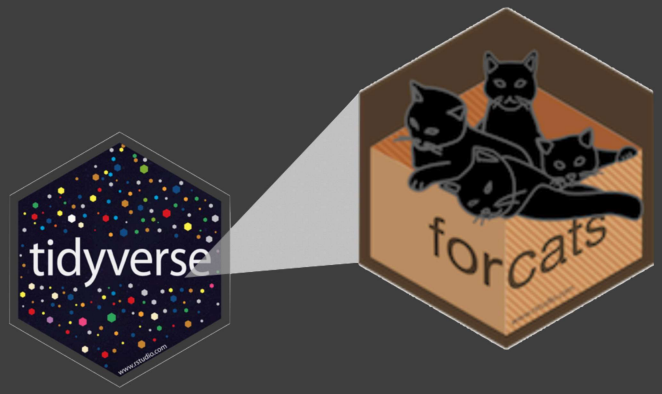

- Les facteurs sont utiles lorsque vous avez des données catégorielles et que vous voulez remplacer l'ordre des vecteurs de caractères pour améliorer l'affichage
- Le package **forcats** fournit une suite d'outils utiles qui résolvent des problèmes courants avec les facteurs

Les fonctions de `forcats`

`focats` possède plusieurs fonctions pour manipuler les facteurs:

- `fct_reorder()` - Réordonne les niveaux d'un facteur en fonction d'une autre variable
- `fct_relevel()` - Réordonne les niveaux d'un facteur
- `fct_infreq()` - Réordonne les niveaux d'un facteur en fonction de leur fréquence
- `fct_lump()` - Regroupe les niveaux d'un facteur en "autres"
- `fct_explicit_na()` - Ajoute un niveau pour les valeurs manquantes

Exemple: starwars

```
1 starwars %>%
2   ggplot(aes(y = hair_color)) +
3   geom_bar()
```

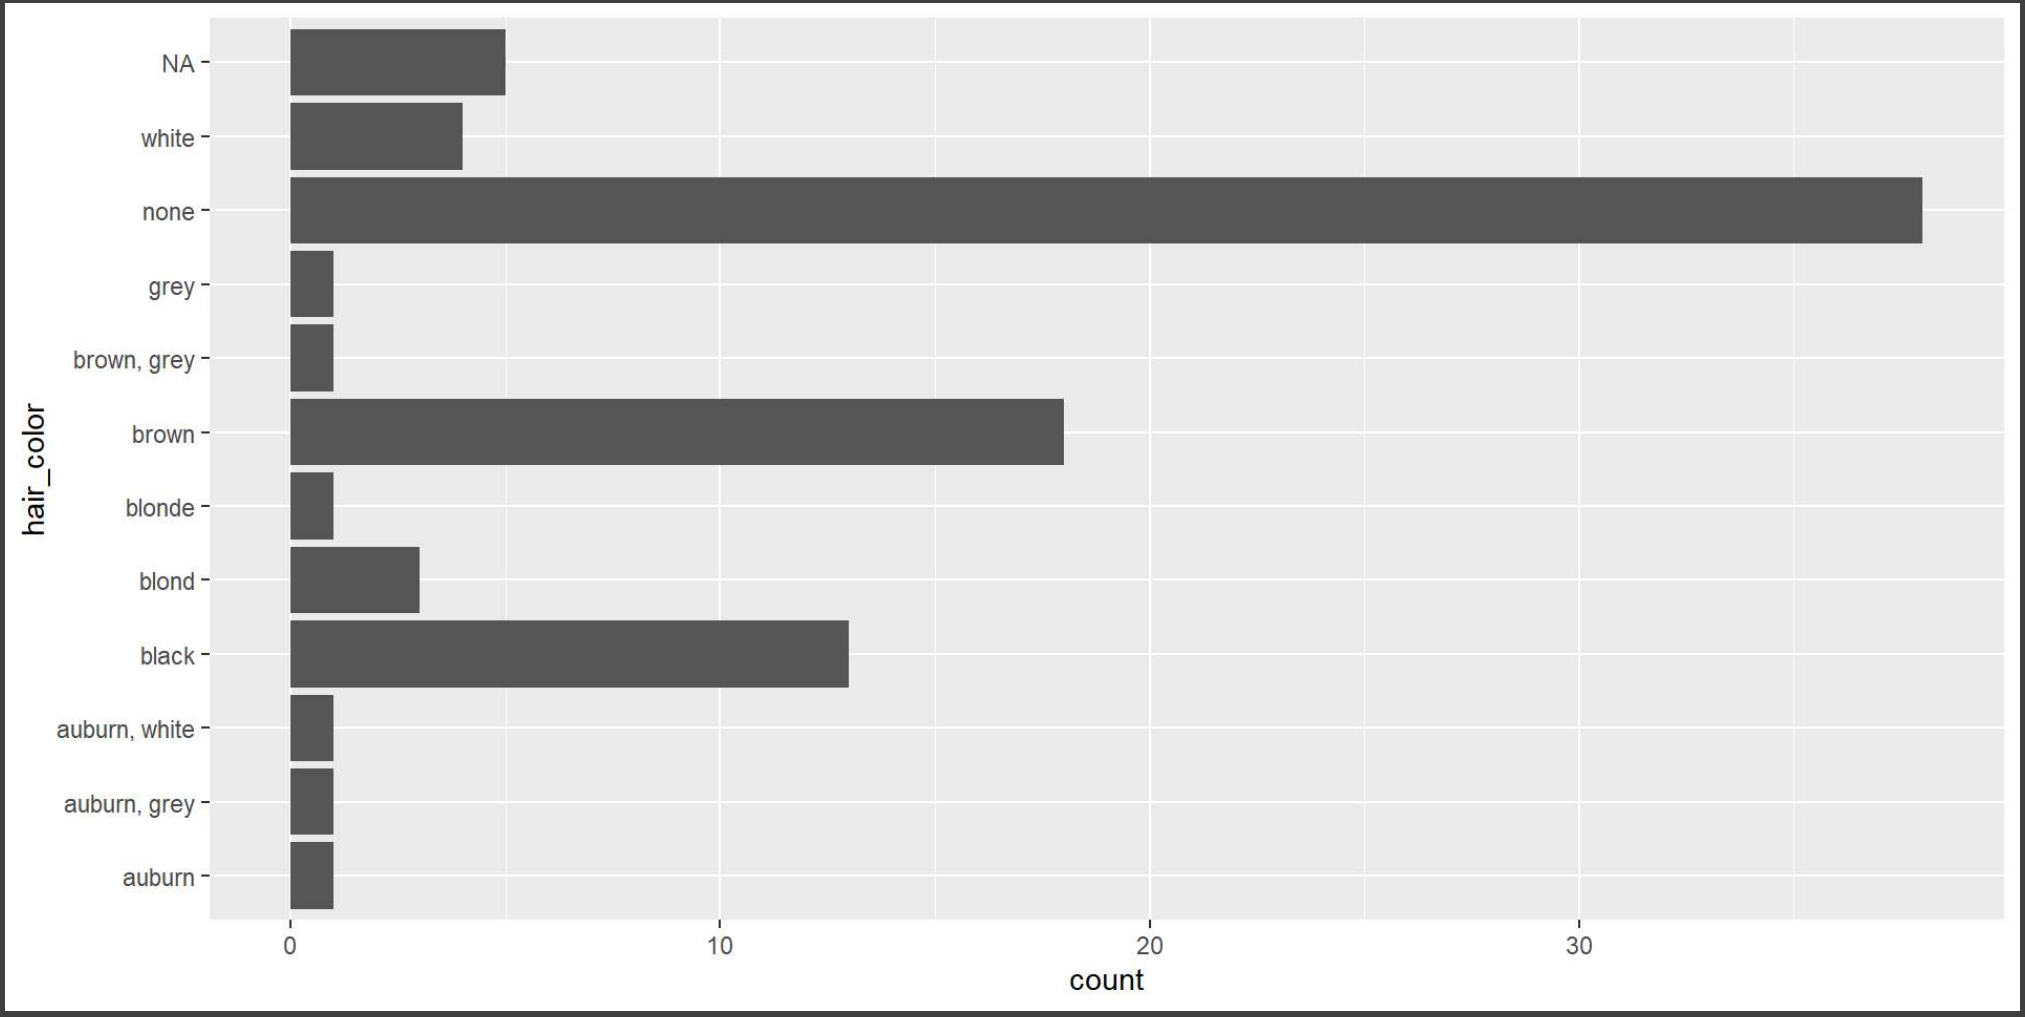

Ordre selon la fréquence : `fct_infreq()`

```
1  starwars %>%
2    ggplot(aes(y = fct_infreq(hair_color))) +
3    geom_bar()
```

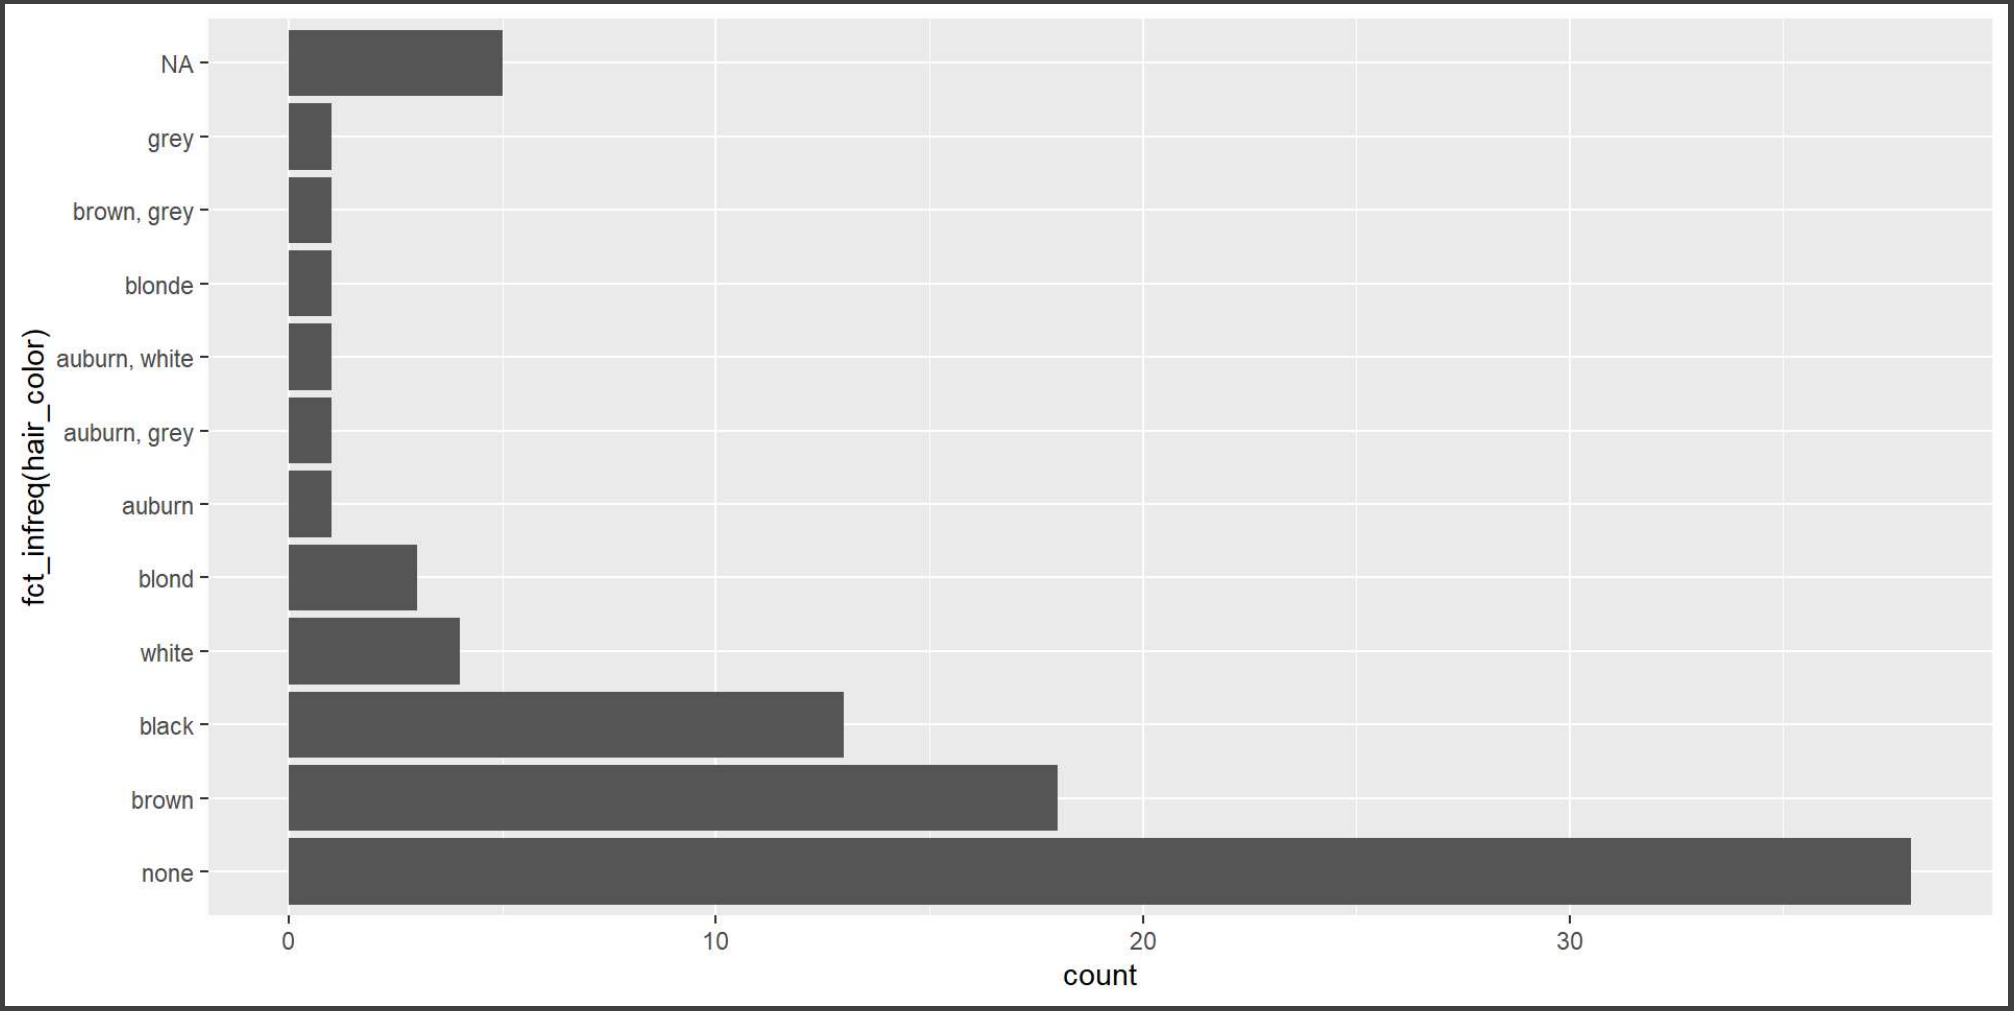

UQTR Université du Québec à Trois-Rivières

Regroupement de facteurs

Utile quand on a beaucoup de niveaux

```
1 starwars %>%
2   count(skin_color, sort = TRUE)
```

```
# A tibble: 31 × 2
   skin_color     n
   <chr>      <int>
 1 fair          17
 2 light         11
 3 dark           6
 4 green          6
 5 grey           6
 6 pale           5
 7 brown          4
 8 blue           2
 9 blue, grey     2
10 none           2
# ℹ 21 more rows
```

… 31 niveaux dans cet exemple !

Regroupement de facteurs : `fct_lump()`

```
starwars %>%
  mutate(skin_color = fct_lump(skin_color, n = 5)) %>%
  count(skin_color, sort = TRUE)
```

```
# A tibble: 6 × 2
  skin_color     n
  <fct>      <int>
1 Other         41
2 fair          17
3 light         11
4 dark           6
5 green          6
6 grey           6
```

Regroupement de facteurs

Regardons maintenant la masse moyenne selon la couleur des yeux:

```
starwars %>%
  mutate(eye_color = fct_lump(eye_color, n = 6)) %>%
  group_by(eye_color) %>%
  summarise(mean_mass = mean(mass, na.rm = TRUE)) %>%
  ggplot(aes(x = eye_color, y = mean_mass)) +
  geom_col()
```

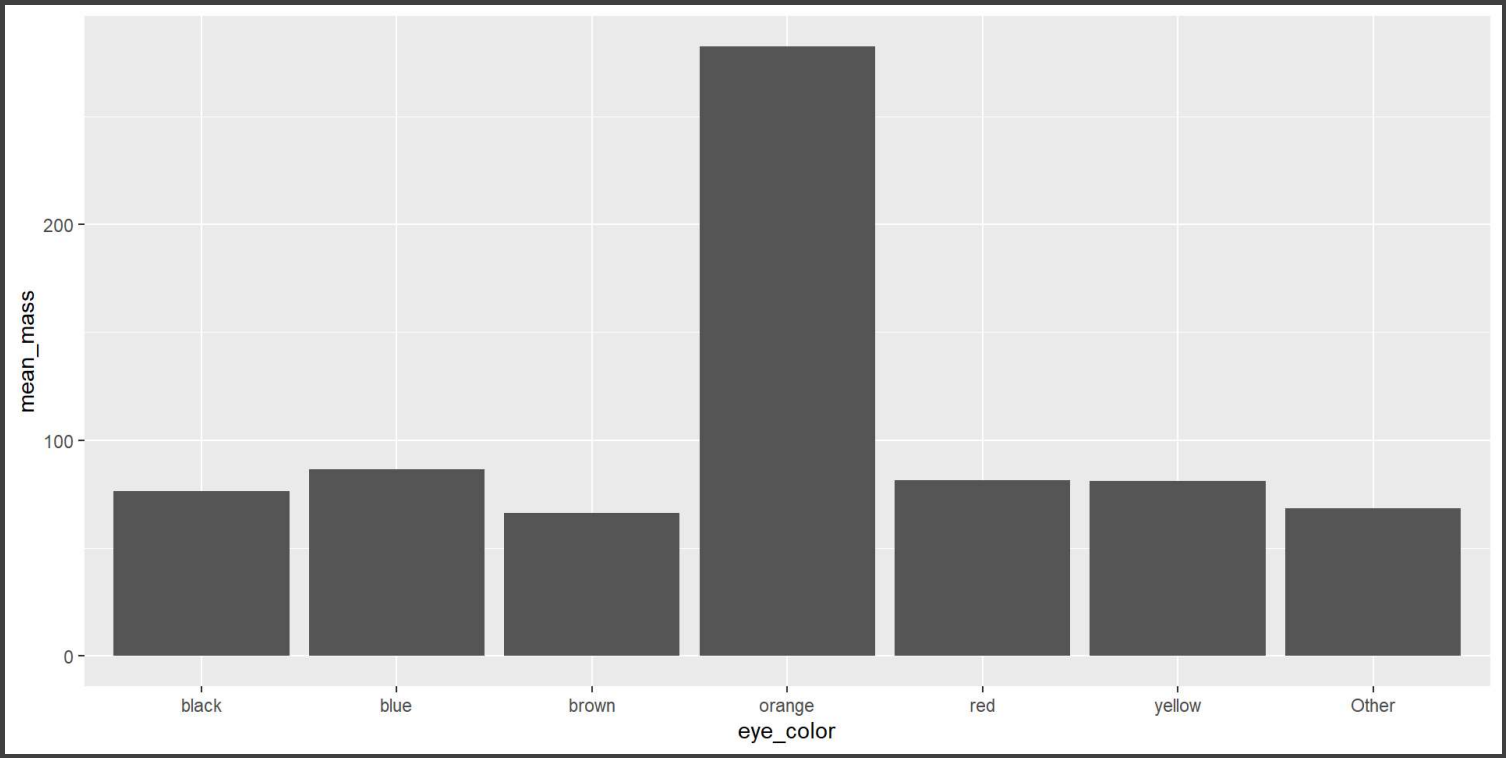

UQTR Université du Québec à Trois-Rivières

Regroupement et changement d'ordre !

Nous allons maintenant regrouper les couleurs des yeux et les ordonner selon la masse moyenne

```
1  starwars %>%
2    mutate(eye_color = fct_lump(eye_color, n = 6)) %>%
3    group_by(eye_color) %>%
4    summarise(mean_mass = mean(mass, na.rm = TRUE)) %>%
5    mutate(eye_color = fct_reorder(eye_color, mean_mass)) %>%
6    ggplot(aes(x = eye_color, y = mean_mass)) +
7    geom_col()
```

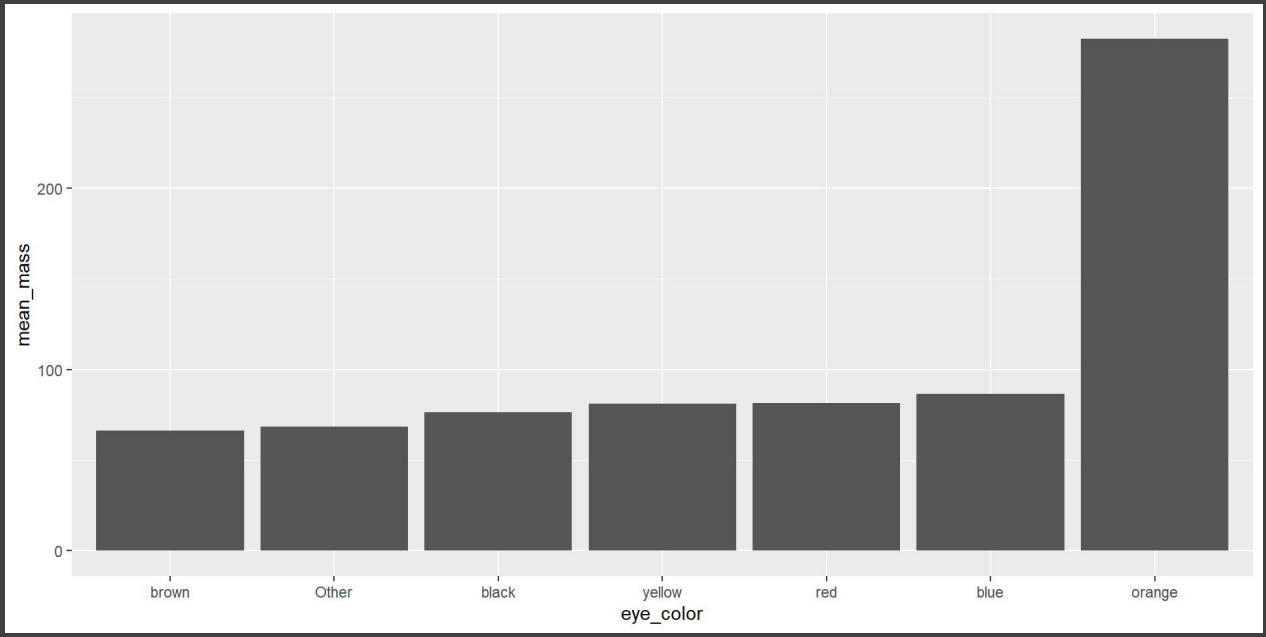

UQTR Université du Québec à Trois-Rivières

Exemple: Hotels

Exemple: Hotels

Choix manuel de l'ordre : `fct_relevel()`

La variable `month.name` est une variable intégrée dans R qui contient les noms des mois en anglais et dans le bon ordre.

```r
hotels <- readr::read_csv("data/hotels.csv")

hotels %>%
  mutate(arrival_date_month = fct_relevel(arrival_date_month, month.name)) %>% # On réordonne les
  group_by(hotel, arrival_date_month) %>%    # group by type d'hotel et mois d'arrivée
  summarise(mean_adr = mean(adr)) %>%        # calcul de l'ADR moyen pour chaque groupe
  ggplot(aes(
    x = arrival_date_month,
    y = mean_adr,                            # mean_adr sur y-axis
    group = hotel,                           # Groupe les lignes par type
    color = hotel)                           # couleur par type
    ) +
  geom_line() +                              # On veut des lignes
  scale_y_continuous(labels = label_dollar()) +
  theme_minimal() +                          # Utilise le minimal theme
  labs(x = "Arrival month",                  # On met à jour les labels
       y = "Mean ADR (average daily rate)",
       title = "Comparison of resort and city hotel prices across months",
       subtitle = "Resort hotel prices soar in the summer while city hotel prices remain\nrelative
       color = "Hotel type") +
  scale_x_discrete(guide = guide_axis(check.overlap = TRUE)) # On s'assure que les labels ne se ch
```

Renommer les niveaux : `fct_recode()`

Si on veut simplement renommer les niveaux, on peut utiliser `fct_recode()`

```
1 cat_lovers %>%
2   mutate(handedness = fct_recode(handedness, gaucher = "left", droitier = "right")) %>%
3   mutate(handedness = fct_infreq(handedness)) %>%
4   ggplot(mapping = aes(x = handedness)) +
5   geom_bar()
```

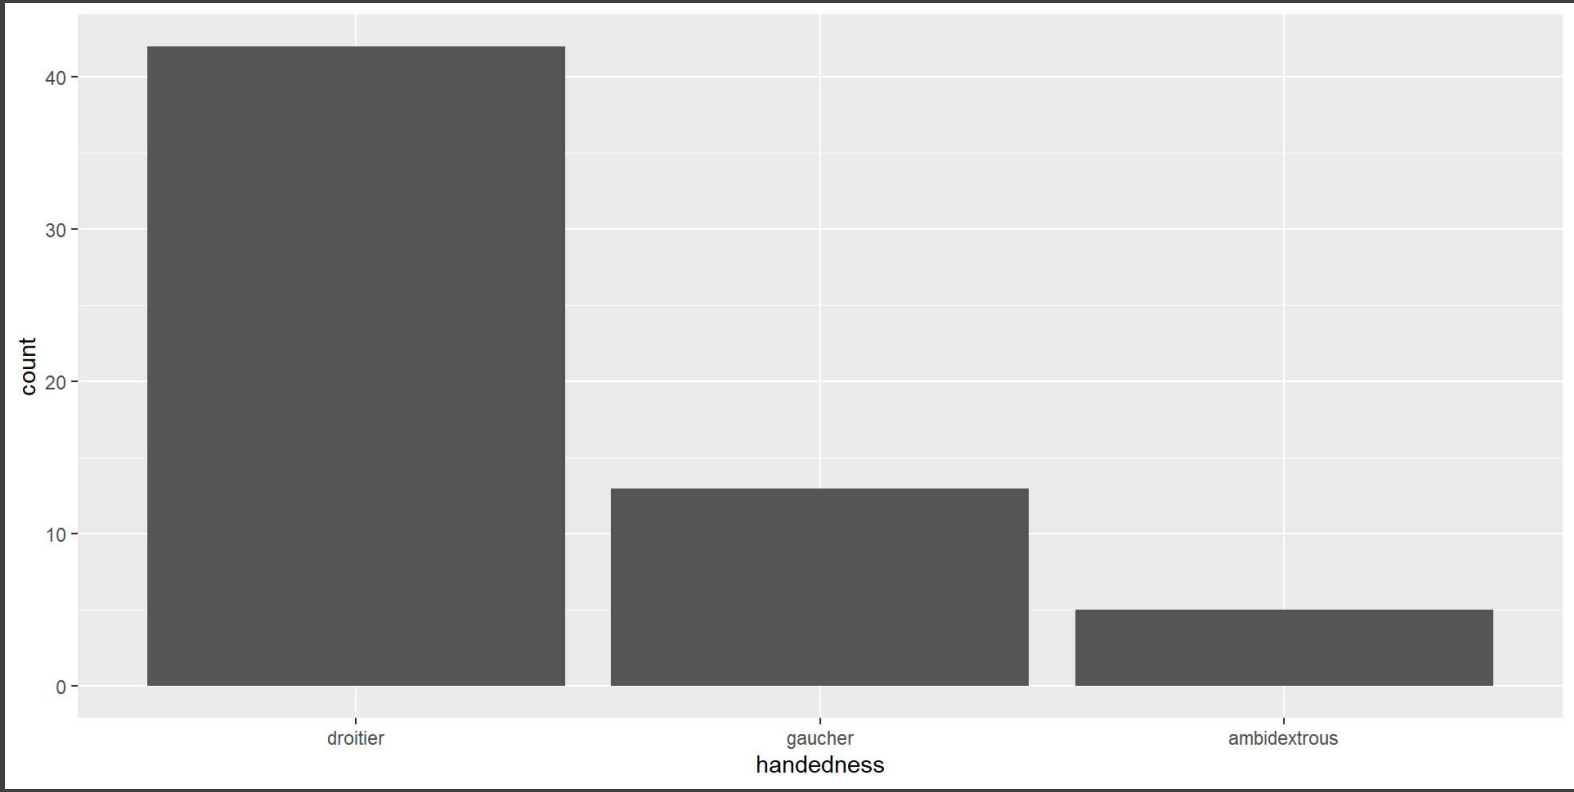

Travailler avec les dates

Dates

- **lubridate** est un package tidyverse-friendly qui facilite la manipulation des dates
- Il ne fait pas partie du coeur tidyverse, donc il doit être installé avec `install.packages("tidyverse)` mais il n'est pas chargé avec lui, et doit être explicitement chargé avec `library(lubridate)`.
  - …

Exemple des hotels

Nous allons voir les bases mais travailler avec des dates peut s’avérer complexe mais cela peut apporter beaucoup à une analyse.

> Calculer et visualiser le nombre de réservations à une date d’arrivée donnée

Étape 1 - Construire la date

```r
library(glue) # glue permet de coller des éléments ensemble

hotels %>%
  mutate(
    arrival_date = glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_month}")
    ) %>%
  relocate(arrival_date) # pour afficher la nouvelle colonne à gauche
```

```
# A tibble: 119,390 × 33
   arrival_date hotel is_canceled lead_time arrival_date_year arrival_date_month
   <glue>       <chr>       <dbl>     <dbl>             <dbl> <chr>
 1 2015 July 1  Reso…           0       342              2015 July
 2 2015 July 1  Reso…           0       737              2015 July
 3 2015 July 1  Reso…           0         7              2015 July
 4 2015 July 1  Reso…           0        13              2015 July
 5 2015 July 1  Reso…           0        14              2015 July
 6 2015 July 1  Reso…           0        14              2015 July
 7 2015 July 1  Reso…           0         0              2015 July
 8 2015 July 1  Reso…           0         9              2015 July
 9 2015 July 1  Reso…           1        85              2015 July
10 2015 July 1  Reso…           1        75              2015 July
# ℹ 119,380 more rows
# ℹ 27 more variables: arrival_date_week_number <dbl>,
#   arrival_date_day_of_month <dbl>, stays_in_weekend_nights <dbl>,
#   stays_in_week_nights <dbl>, adults <dbl>, children <dbl>, babies <dbl>,
#   meal <chr>, country <chr>, market_segment <chr>,
#   distribution_channel <chr>, is_repeated_guest <dbl>,
#   previous_cancellations <dbl>, previous_bookings_not_canceled <dbl>, …
```

Étape 2 - Compter les réservations par dates

```
1 hotels %>%
2   mutate(arrival_date = glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_month}
3   count(arrival_date)
```

```
# A tibble: 793 × 2
   arrival_date       n
   <glue>         <int>
 1 2015 August 1    110
 2 2015 August 10   207
 3 2015 August 11   117
 4 2015 August 12   133
 5 2015 August 13   107
 6 2015 August 14   329
 7 2015 August 15   190
 8 2015 August 16    98
 9 2015 August 17   188
10 2015 August 18    94
# ℹ 783 more rows
```

Étape 4 - Visualiser

```
1  hotels %>%
2    mutate(arrival_date = glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_month}
3    count(arrival_date) %>%
4    ggplot(aes(x = arrival_date, y = n, group = 1)) +
5    geom_line()
```

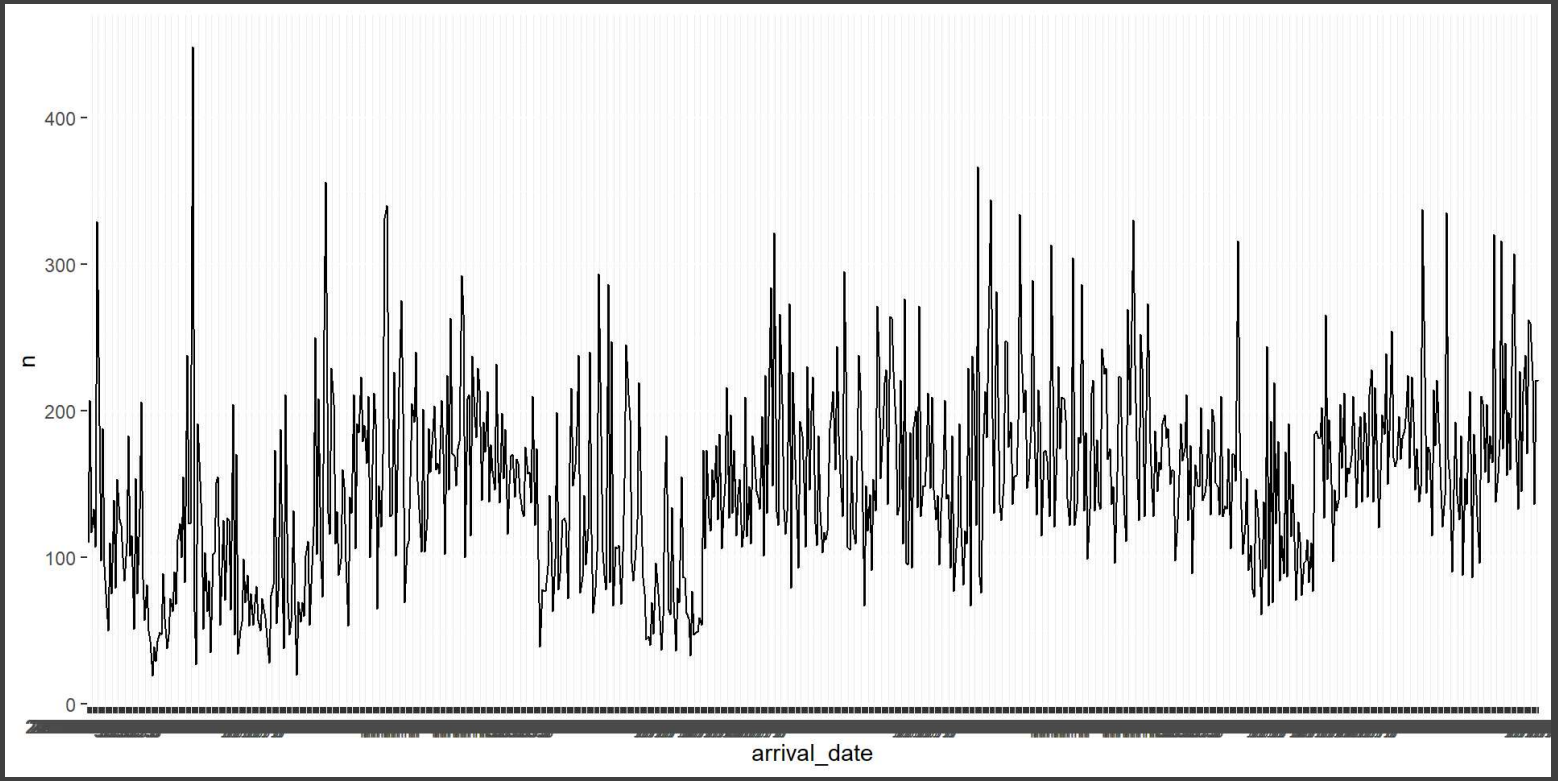

Quel est le problème ici ?

Étape 1 - Construire la date (comme une date)

```r
library(lubridate) # pour les dates

hotels %>%
  mutate(
    arrival_date = ymd(glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_month}"
    ) %>%
  relocate(arrival_date)
```

```
# A tibble: 119,390 × 33
   arrival_date hotel is_canceled lead_time arrival_date_year arrival_date_month
   <date>       <chr>       <dbl>     <dbl>              <dbl> <chr>
 1 2015-07-01   Reso…           0       342               2015 July
 2 2015-07-01   Reso…           0       737               2015 July
 3 2015-07-01   Reso…           0         7               2015 July
 4 2015-07-01   Reso…           0        13               2015 July
 5 2015-07-01   Reso…           0        14               2015 July
 6 2015-07-01   Reso…           0        14               2015 July
 7 2015-07-01   Reso…           0         0               2015 July
 8 2015-07-01   Reso…           0         9               2015 July
 9 2015-07-01   Reso…           1        85               2015 July
10 2015-07-01   Reso…           1        75               2015 July
# ℹ 119,380 more rows
# ℹ 27 more variables: arrival_date_week_number <dbl>,
#   arrival_date_day_of_month <dbl>, stays_in_weekend_nights <dbl>,
#   stays_in_week_nights <dbl>, adults <dbl>, children <dbl>, babies <dbl>,
#   meal <chr>, country <chr>, market_segment <chr>,
#   distribution_channel <chr>, is_repeated_guest <dbl>,
#   previous_cancellations <dbl>, previous_bookings_not_canceled <dbl>, …
```

Étape 2 - Compter les réservations par dates

```
hotels %>%
  mutate(arrival_date = ymd(glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_mo
  count(arrival_date)
```

```
# A tibble: 793 × 2
   arrival_date     n
   <date>       <int>
 1 2015-07-01     122
 2 2015-07-02      93
 3 2015-07-03      56
 4 2015-07-04      88
 5 2015-07-05      53
 6 2015-07-06      75
 7 2015-07-07      54
 8 2015-07-08      69
 9 2015-07-09      80
10 2015-07-10      51
# ℹ 783 more rows
```

Étape 3a - Visualiser

```
1 hotels %>%
2   mutate(arrival_date = ymd(glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_mo
3   count(arrival_date) %>%
4   ggplot(aes(x = arrival_date, y = n, group = 1)) +
5   geom_line()
```

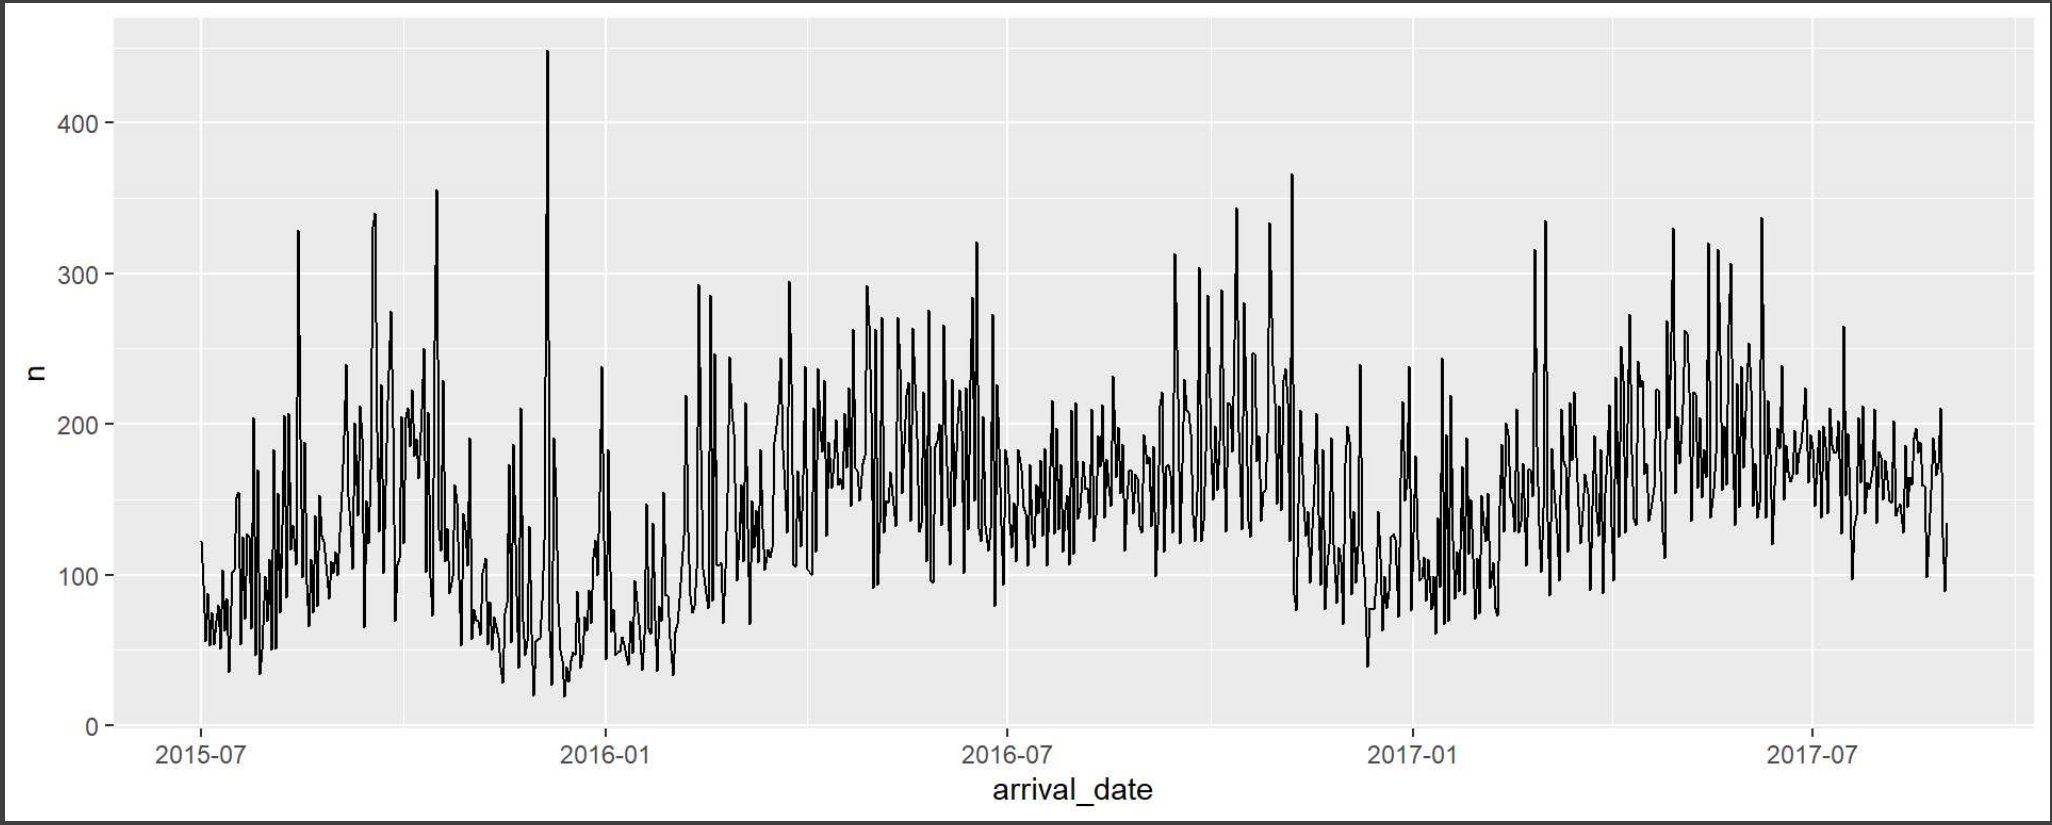

UQTR Université du Québec à Trois-Rivières

Étape 3b - Visualiser avec une courbe

```
1 hotels %>%
2   mutate(arrival_date = ymd(glue("{arrival_date_year} {arrival_date_month} {arrival_date_day_of_mo
3   count(arrival_date) %>%
4   ggplot(aes(x = arrival_date, y = n, group = 1)) +
5   geom_smooth() #<<
```

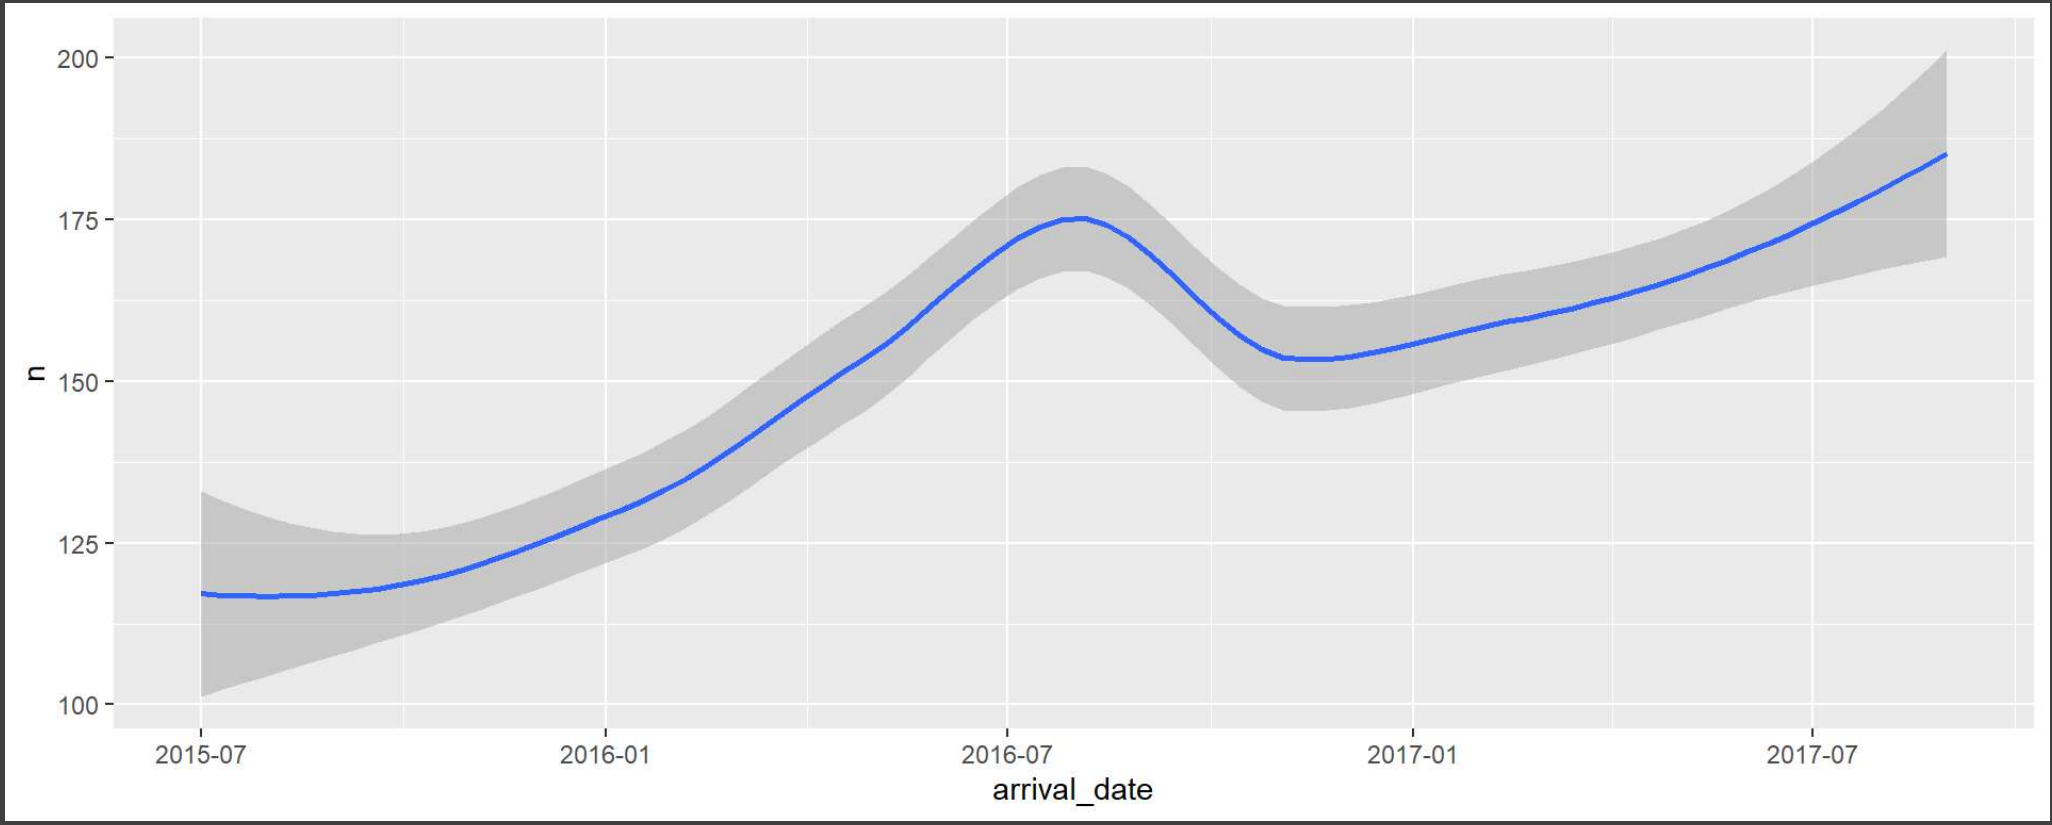

UQTR Université du Québec à Trois-Rivières

Étude de cas: Religion et Revenu

Les données

Income distribution

Chart | **Table** | Share

Religious tradition	Less than $30,000	$30,000-$49,999	$50,000-$99,999	$100,000 or more	Sample size
Buddhist	36%	18%	32%	13%	233
Catholic	36%	19%	26%	19%	6,137
Evangelical Protestant	35%	22%	28%	14%	7,462
Hindu	17%	13%	34%	36%	172
Historically Black Protestant	53%	22%	17%	8%	1,704
Jehovah's Witness	48%	25%	22%	4%	208
Jewish	16%	15%	24%	44%	708
Mainline Protestant	29%	20%	28%	23%	5,208
Mormon	27%	20%	33%	20%	594
Muslim	34%	17%	29%	20%	205
Orthodox Christian	18%	17%	36%	29%	155
Unaffiliated (religious "nones")	33%	20%	26%	21%	6,790

Source: Religious Landscape Study

Les données

```
Rows: 12
Columns: 6
$ `Religious tradition` <chr> "Buddhist", "Catholic", "Evangelical Protestant"…
$ `Less than $30,000`   <dbl> 0.36, 0.36, 0.35, 0.17, 0.53, 0.48, 0.16, 0.29, …
$ `$30,000-$49,999`     <dbl> 0.18, 0.19, 0.22, 0.13, 0.22, 0.25, 0.15, 0.20, …
$ `$50,000-$99,999`     <dbl> 0.32, 0.26, 0.28, 0.34, 0.17, 0.22, 0.24, 0.28, …
$ `$100,000 or more`    <dbl> 0.13, 0.19, 0.14, 0.36, 0.08, 0.04, 0.44, 0.23, …
$ `Sample Size`         <dbl> 233, 6137, 7462, 172, 1704, 208, 708, 5208, 594,…
```

Noms des colonnes

```
rel_inc %>%
  rename(
    religion = `Religious tradition`,
    n = `Sample Size`
  )
```

```
# A tibble: 12 × 6
   religion              `Less than $30,000` `$30,000-$49,999` `$50,000-$99,999`
   <chr>                               <dbl>              <dbl>              <dbl>
 1 "Buddhist"                           0.36               0.18               0.32
 2 "Catholic"                           0.36               0.19               0.26
 3 "Evangelical Protest…                0.35               0.22               0.28
 4 "Hindu"                              0.17               0.13               0.34
 5 "Historically Black …                0.53               0.22               0.17
 6 "Jehovah's Witness"                  0.48               0.25               0.22
 7 "Jewish"                             0.16               0.15               0.24
 8 "Mainline Protestant"                0.29               0.2                0.28
 9 "Mormon"                             0.27               0.2                0.33
10 "Muslim"                             0.34               0.17               0.29
11 "Orthodox Christian"                 0.18               0.17               0.36
12 "Unaffiliated (relig…                0.33               0.2                0.26
# ℹ 2 more variables: `$100,000 or more` <dbl>, n <dbl>
```

Tidy ?

```
# A tibble: 12 × 6
   religion              `Less than $30,000` `$30,000-$49,999` `$50,000-$99,999`
   <chr>                               <dbl>             <dbl>             <dbl>
 1 "Buddhist"                           0.36              0.18              0.32
 2 "Catholic"                           0.36              0.19              0.26
 3 "Evangelical Protest…                0.35              0.22              0.28
 4 "Hindu"                              0.17              0.13              0.34
 5 "Historically Black …                0.53              0.22              0.17
 6 "Jehovah's Witness"                  0.48              0.25              0.22
 7 "Jewish"                             0.16              0.15              0.24
 8 "Mainline Protestant"                0.29              0.2               0.28
 9 "Mormon"                             0.27              0.2               0.33
10 "Muslim"                             0.34              0.17              0.29
11 "Orthodox Christian"                 0.18              0.17              0.36
12 "Unaffiliated (relig…                0.33              0.2               0.26
# ℹ 2 more variables: `$100,000 or more` <dbl>, n <dbl>
```

Pivoter les données

```r
rel_inc %>%
  rename(
    religion = `Religious tradition`,
    n = `Sample Size`
  ) %>%
  pivot_longer(
    cols = -c(religion, n),    # Toutes les colonnes sauf religion et n
    names_to = "income",
    values_to = "proportion"
  ) %>%
  print(n = 15)
```

Tidy !

```
# A tibble: 48 × 4
   religion                    n income            proportion
   <chr>                   <dbl> <chr>                  <dbl>
 1 Buddhist                  233 Less than $30,000       0.36
 2 Buddhist                  233 $30,000-$49,999         0.18
 3 Buddhist                  233 $50,000-$99,999         0.32
 4 Buddhist                  233 $100,000 or more        0.13
 5 Catholic                 6137 Less than $30,000       0.36
 6 Catholic                 6137 $30,000-$49,999         0.19
 7 Catholic                 6137 $50,000-$99,999         0.26
 8 Catholic                 6137 $100,000 or more        0.19
 9 Evangelical Protestant   7462 Less than $30,000       0.35
10 Evangelical Protestant   7462 $30,000-$49,999         0.22
11 Evangelical Protestant   7462 $50,000-$99,999         0.28
12 Evangelical Protestant   7462 $100,000 or more        0.14
13 Hindu                     172 Less than $30,000       0.17
14 Hindu                     172 $30,000-$49,999         0.13
15 Hindu                     172 $50,000-$99,999         0.34
# ℹ 33 more rows
```

Calcul des fréquences

```r
rel_inc %>%
  rename(
    religion = `Religious tradition`,
    n = `Sample Size`
  ) %>%
  pivot_longer(
    cols = -c(religion, n),
    names_to = "income",
    values_to = "proportion"
  ) %>%
  mutate(frequency = round(proportion * n))
```

```
# A tibble: 48 × 5
   religion                     n income            proportion frequency
   <chr>                    <dbl> <chr>                  <dbl>     <dbl>
 1 Buddhist                   233 Less than $30,000       0.36        84
 2 Buddhist                   233 $30,000-$49,999         0.18        42
 3 Buddhist                   233 $50,000-$99,999         0.32        75
 4 Buddhist                   233 $100,000 or more        0.13        30
 5 Catholic                  6137 Less than $30,000       0.36      2209
 6 Catholic                  6137 $30,000-$49,999         0.19      1166
 7 Catholic                  6137 $50,000-$99,999         0.26      1596
 8 Catholic                  6137 $100,000 or more        0.19      1166
 9 Evangelical Protestant    7462 Less than $30,000       0.35      2612
10 Evangelical Protestant    7462 $30,000-$49,999         0.22      1642
# ℹ 38 more rows
```

Enregistrer les données

```
rel_inc_long <- rel_inc %>%
  rename(
    religion = `Religious tradition`,
    n = `Sample Size`
  ) %>%
  pivot_longer(
    cols = -c(religion, n),
    names_to = "income",
    values_to = "proportion"
  ) %>%
  mutate(frequency = round(proportion * n))
```

Visualisation

```
1  rel_inc_long %>%
2    ggplot(aes(y = religion, x = frequency)) +
3    geom_col()
```

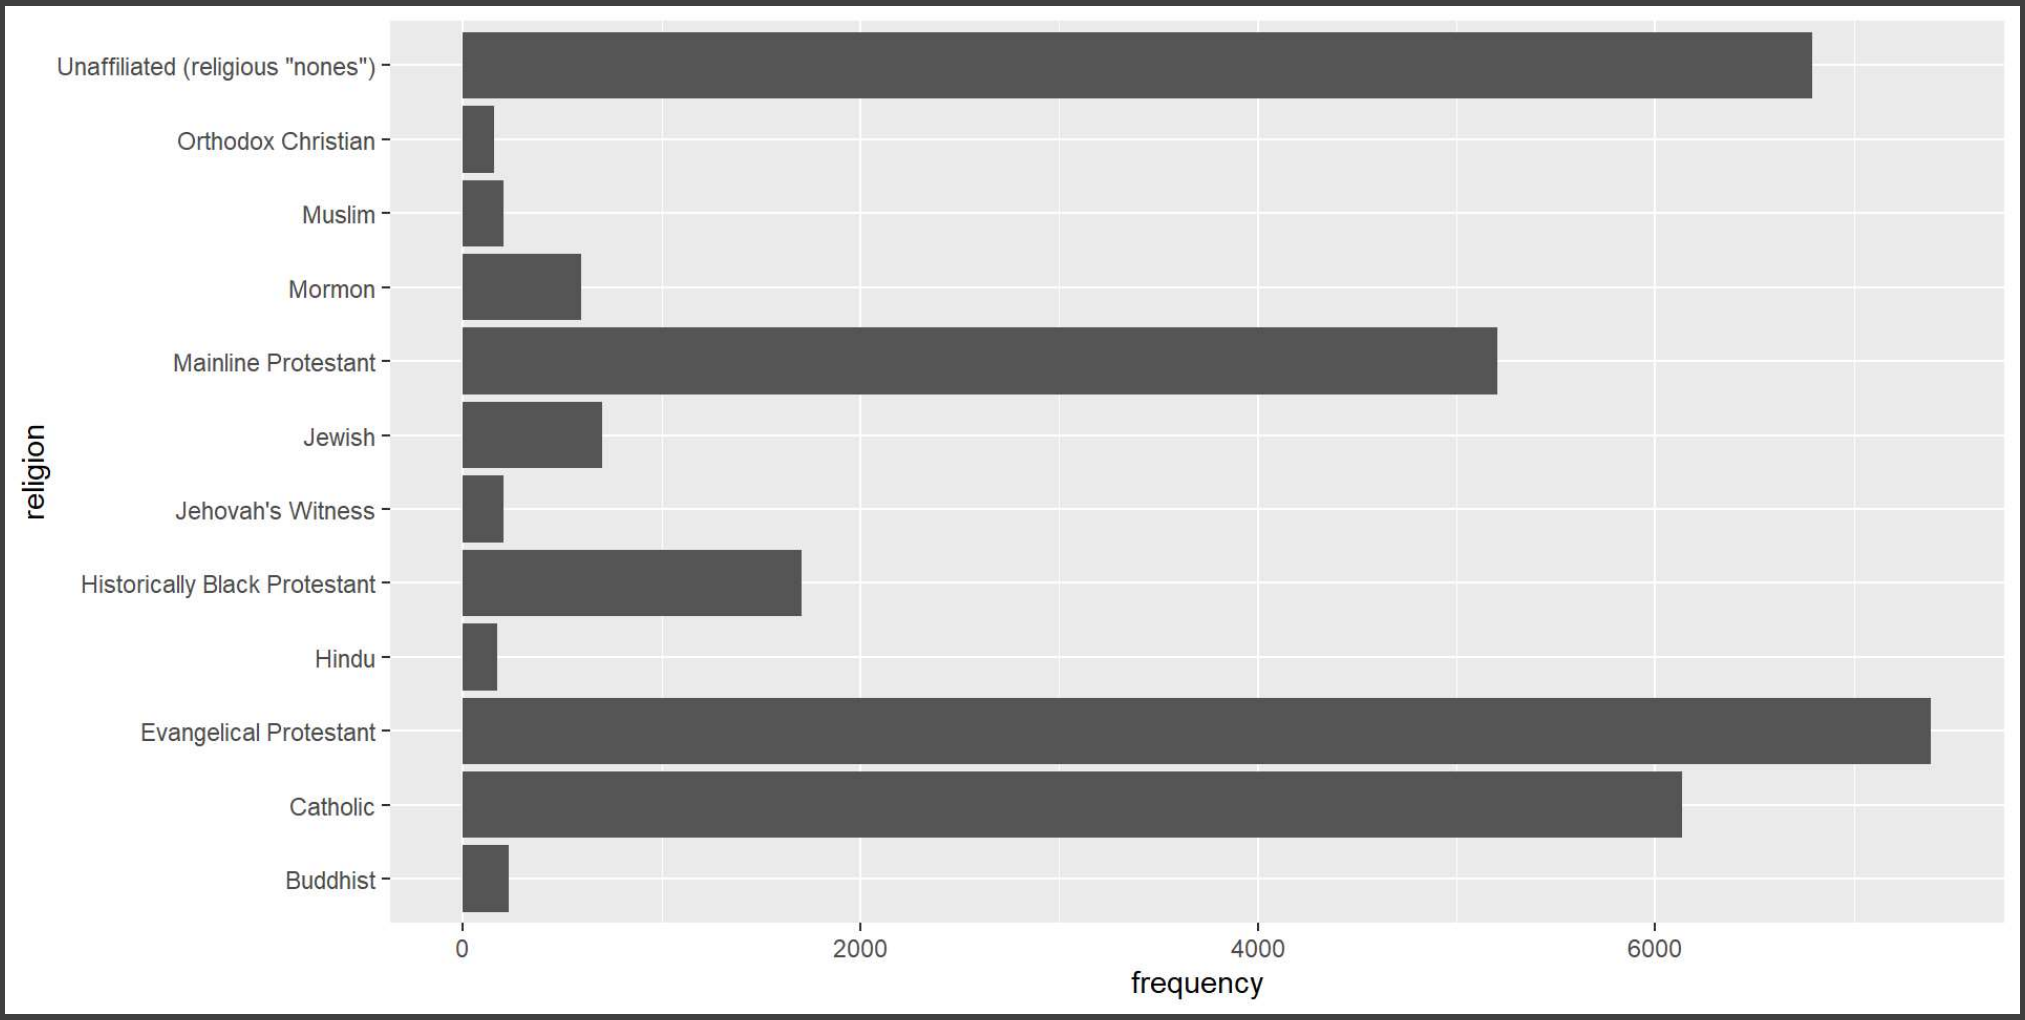

UQTR Université du Québec à Trois-Rivières

Recodage des religions

```
rel_inc_long <- rel_inc_long %>%
  mutate(religion = case_when(
    religion == "Evangelical Protestant"           ~ "Ev. Protestant",
    religion == "Historically Black Protestant"    ~ "Hist. Black Protestant",
    religion == 'Unaffiliated (religious "nones")' ~ "Unaffiliated",
    TRUE                                           ~ religion
  ))
```

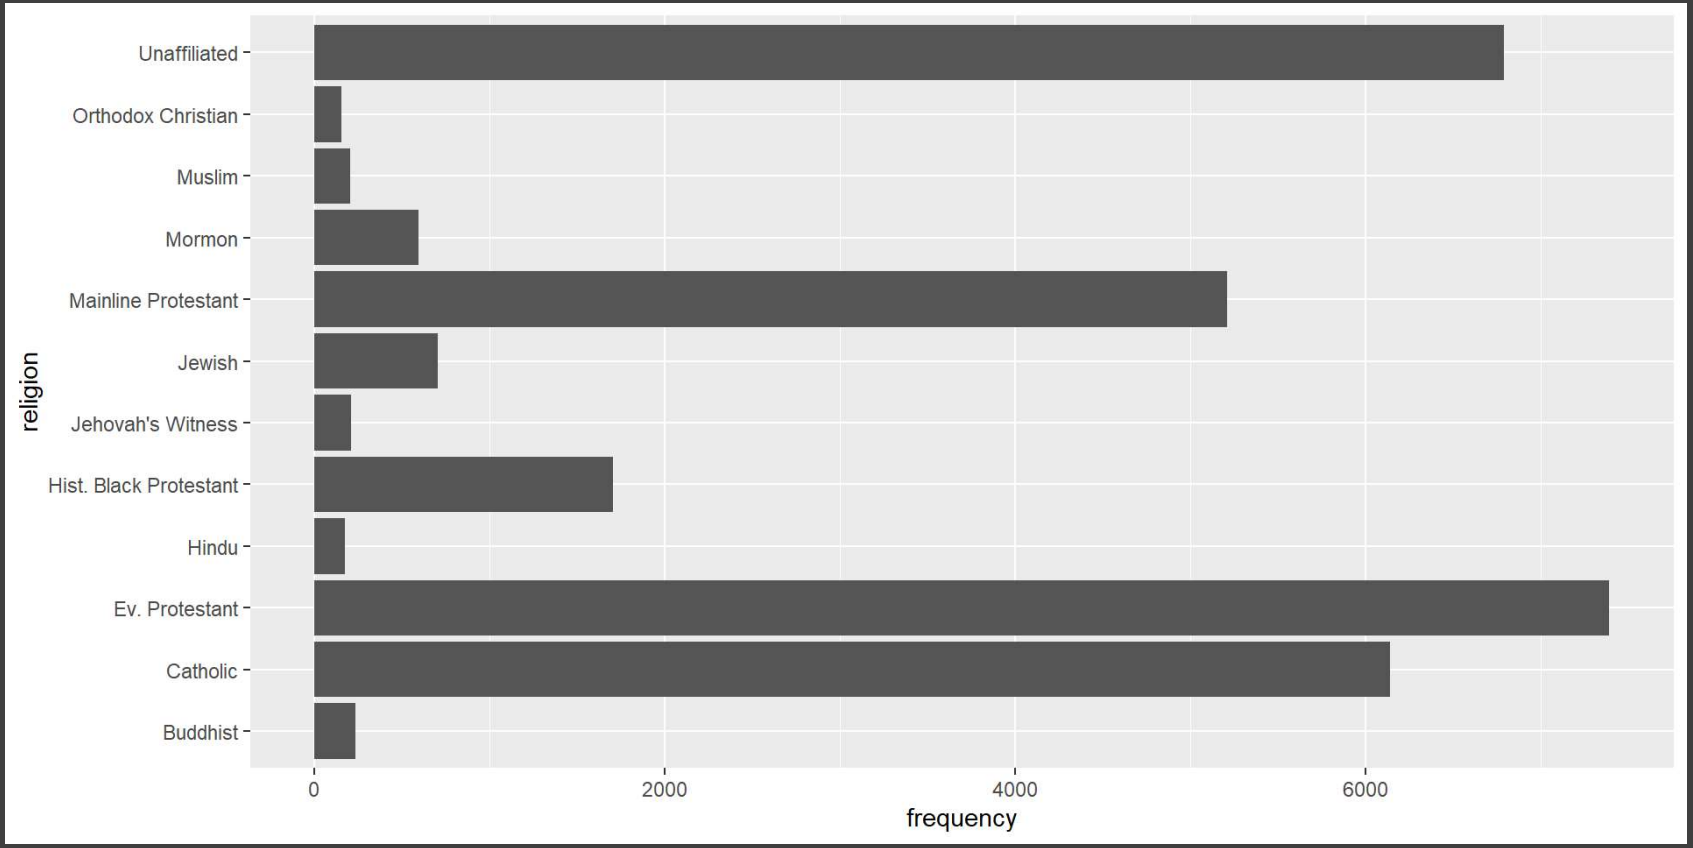

UQTR Université du Québec à Trois-Rivières

On inverse l'ordre

```
1  rel_inc_long <- rel_inc_long %>%
2    mutate(religion = fct_rev(religion))
```

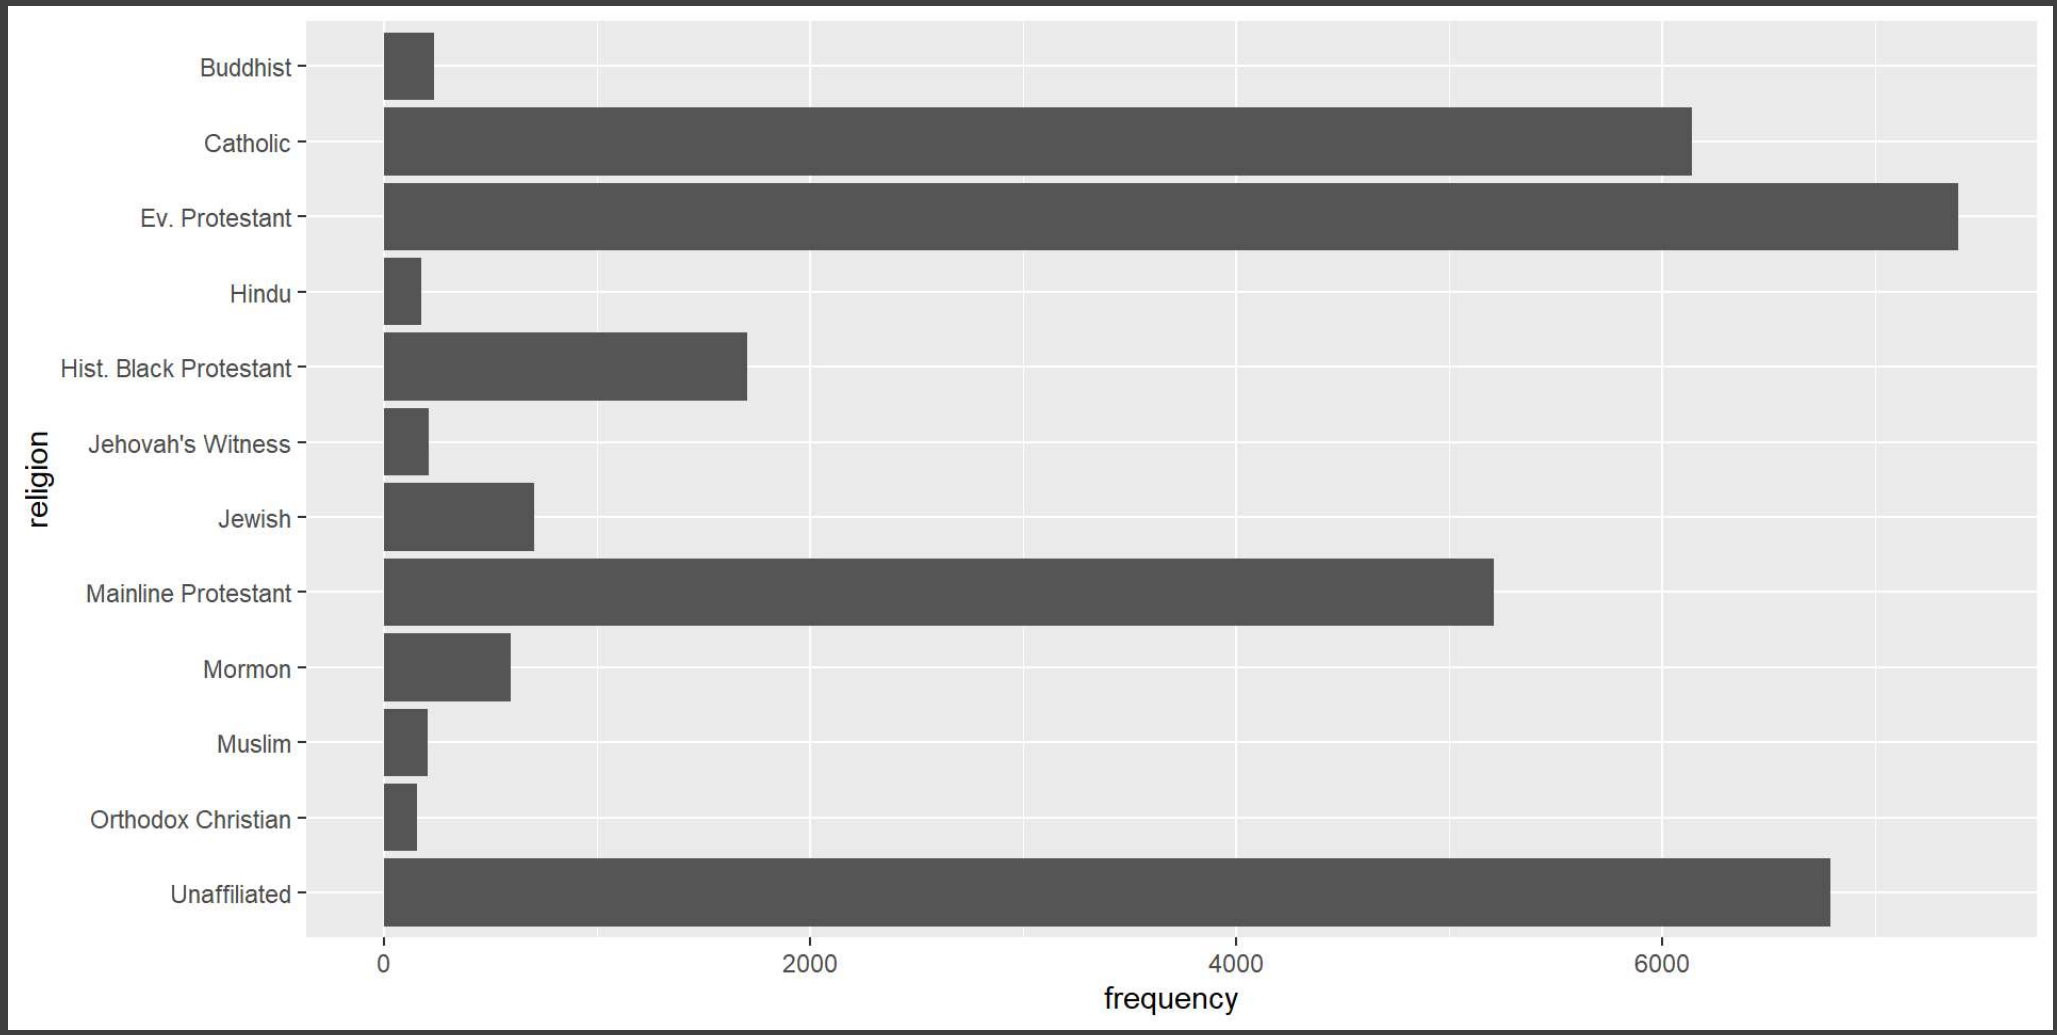

On nettoie tout ça

```
ggplot(rel_inc_long, aes(y = religion, x = frequency, fill = income)) +
  geom_col(position = "fill") +                          # On veut des barres pleines pour les prop
  scale_fill_viridis_d() +                               # On change les couleurs
  theme_minimal() +                                      # On change le thème
  theme(legend.position = "bottom") +                    # On met la légende en bas
  guides(fill = guide_legend(nrow = 2, byrow = TRUE)) + # On met la légende sur 2 lignes
  labs(                                                  # On met à jour les labels
    x = "Proportion", y = "",
    title = "Income distribution by religious group",
    subtitle = "Source: Pew Research Center, Religious Landscape Study",
    fill = "Income"
    )
```

TADA ?

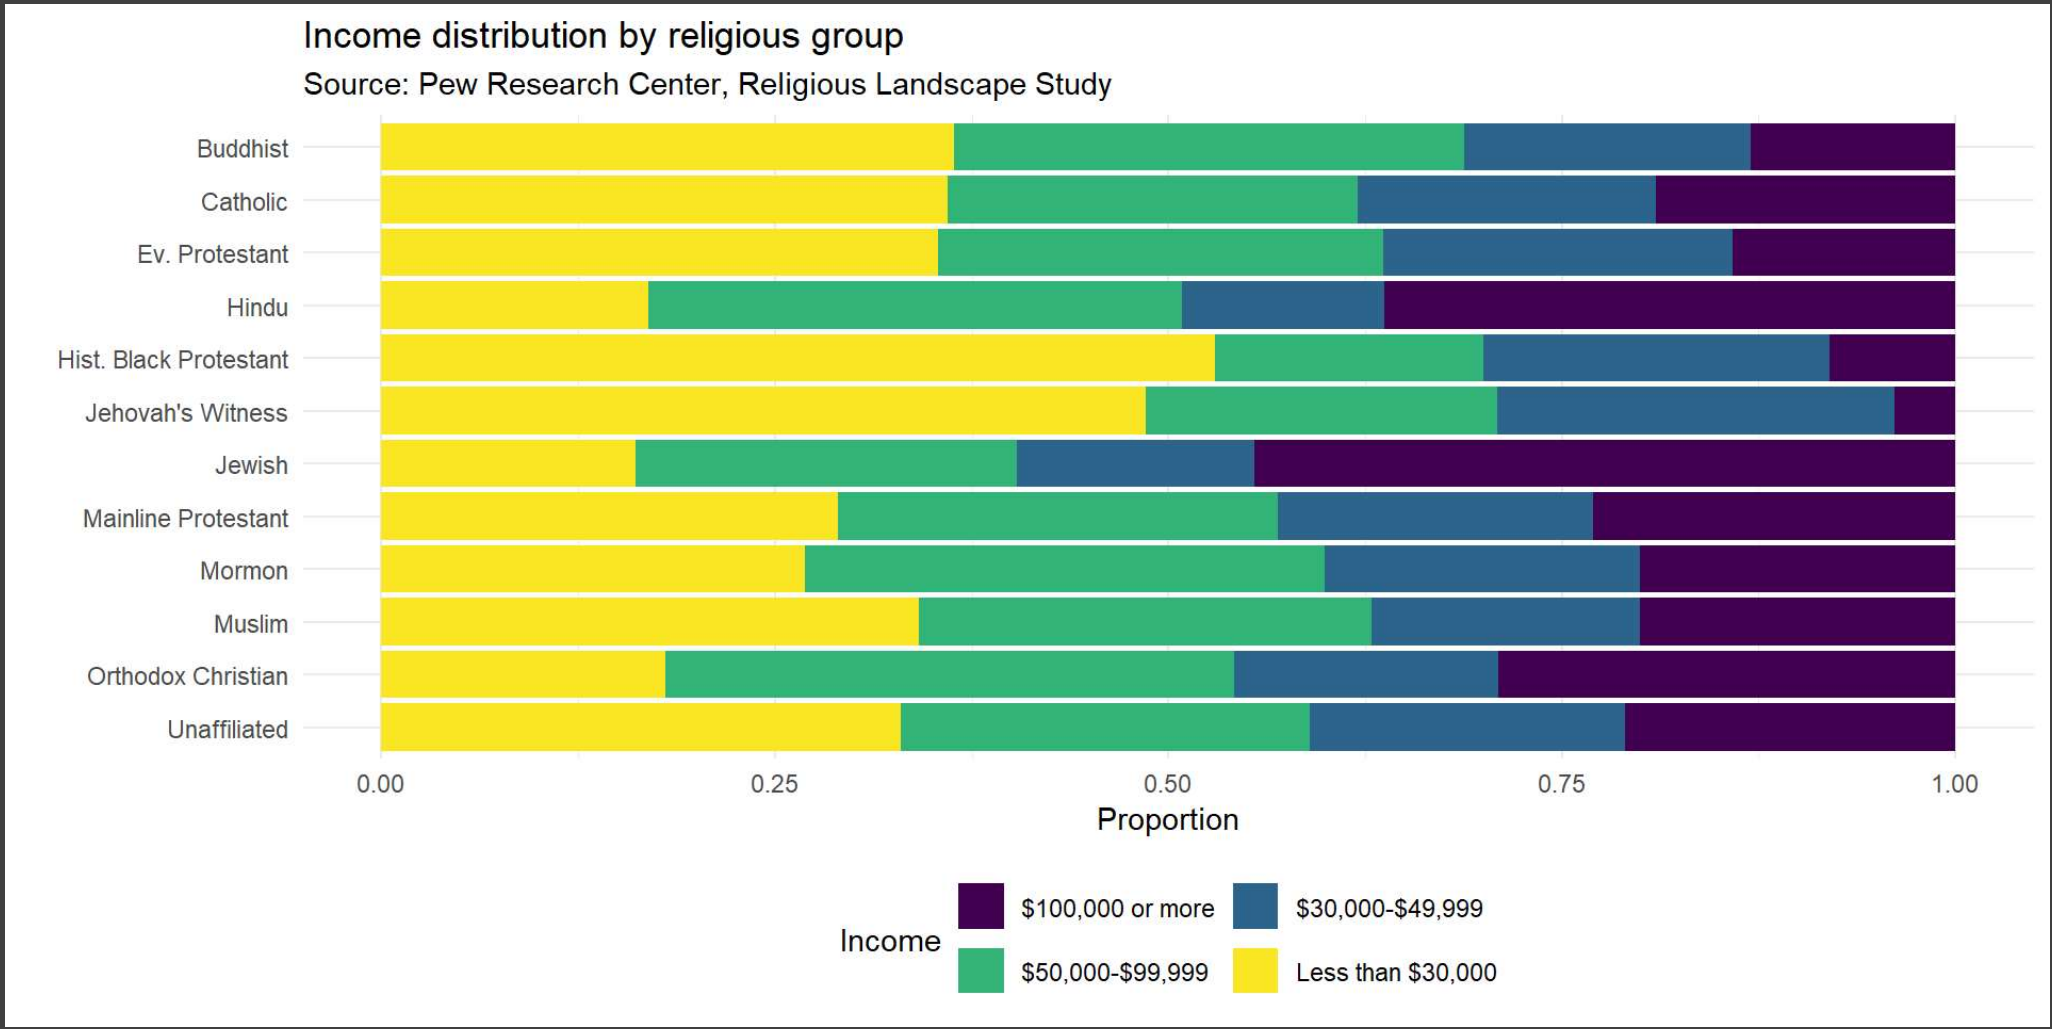
Income distribution by religious group
Source: Pew Research Center, Religious Landscape Study
Buddhist
Catholic
Ev. Protestant
Hindu
Hist. Black Protestant
Jehovah's Witness
Jewish
Mainline Protestant
Mormon
Muslim
Orthodox Christian
Unaffiliated
0.00
0.25
0.50
0.75
1.00
Proportion
Income
$100,000 or more
$30,000-$49,999
$50,000-$99,999
Less than $30,000

On veut les revenu dans le bon ordre !

```
1  rel_inc_long <- rel_inc_long %>%
2    mutate(income = fct_relevel(income, "$100,000 or more", "$50,000-$99,999", "$30,000-$49,999", "I
```

TADA !

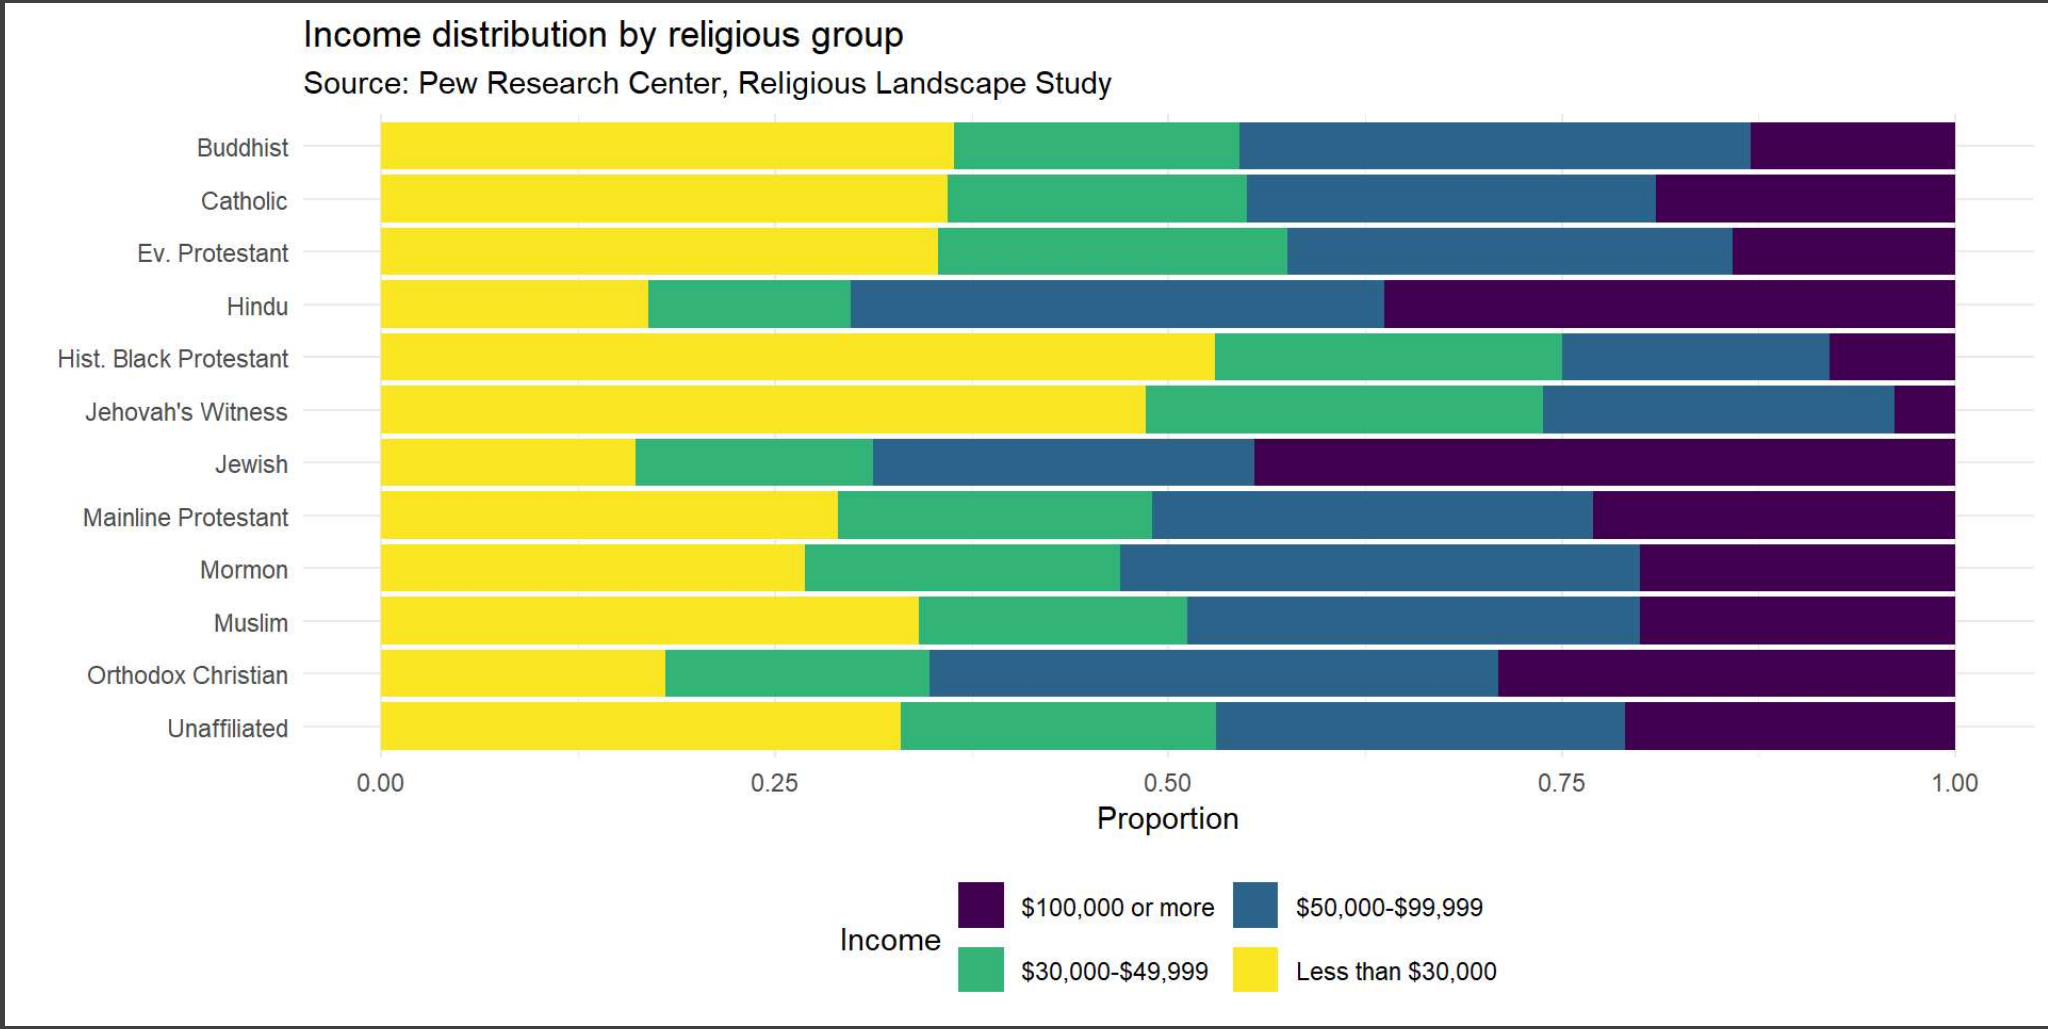

Figure 1

UQTR Université du Québec à Trois-Rivières

Références